Guion 2: Compresión sin pérdida Código de Huffman

Información sobre la entrega de la práctica

Las prácticas se entregarán en un único fichero comprimido Practica02ApellidoNombre.zip. El fichero contendrá:

- Las funciones de Matlab a realizar en ficheros .m con los nombres de las funciones que se indiquen en el guion.
- Los trozos de código a realizar, que se entregarán todos en los pasos correspondientes de un único fichero .m llamado Practica02ApellidoNombre.m . Este fichero lo crearás modificando el fichero .m Practica02MolinaRafael.m en el servidor.
- Las discusiones y respuestas solicitadas en el guion se entregarán en un único fichero pdf. El nombre del fichero será Practica02ApellidoNombre.pdf. Lo construirás editando Practica02MolinaRafael.doc y salvándolo en formato pdf.

En este guion estudiaremos el código de Huffman como método de compresión de datos sin pérdida, es decir, si se comprimen y descomprimen los datos se vuelven a obtener los datos originales.

Sobre la Codificación Huffman

Puedes codificar ficheros de datos mediante codificación Huffman utilizando el software desarrollado por Michael Dipperstein. En la página web de Michael Dipperstein se puede encontrar una clara explicación del algoritmo y las consideraciones de implementación del mismo. Aunque nosotros haremos las prácticas en Matlab te recomendamos que visites el sitio de Michael Dipperstein, contiene unas páginas muy buenas sobre compresión.

Codificación Huffman usando Matlab

Paso 1

Vamos a comenzar suponiendo que tenemos una fuente de la que conocemos los símbolos que genera y la probabilidad de cada una de ellos. Matlab nos permite generar el código de Huffman de una forma muy sencilla

```
A=[1:5];
p=[0.2 0.4 0.2 0.1 0.1];
D=huffmandict(A,p);
for i=1:length(A)
      fprintf('Letra Alfabeto %s Código %s\
      n',num2str(D{i,1}),num2str(D{i,2}))
end
```

La salida de este trozo de código sería

```
Letra Alfabeto 1 Código 0  0  0
Letra Alfabeto 2 Código 1
Letra Alfabeto 3 Código 0  1
Letra Alfabeto 4 Código 0  0  1  1
Letra Alfabeto 5 Código 0  0  1  0
```

Paso 2

Podemos utilizar otros símbolos para los elementos del alfabeto. Halla y muestra, siguiendo el esquema del paso anterior, el código de Huffman correspondiente al alfabeto {P,Q,R,S,T} con probabilidades p=[0.2 0.4 0.2 0.1 0.1]. Cuya ejecución debe producir la salida que se muestra más abajo. Incluye el código en el paso 2 de Practica02ApellidoNombre.m

```
Letra Alfabeto P Código 0  0  0
Letra Alfabeto Q Código 1
Letra Alfabeto R Código 0  1
Letra Alfabeto S Código 0  0  1  1
Letra Alfabeto T Código 0  0  1  0
```

Paso 3

Podemos utilizar la función huffmandict para construir diccionarios de máxima o mínima varianza. El siguiente ejemplo construye el código de Huffman con mínima varianza para el alfabeto A=[1:5] y probabilidades p=[0.2 0.4 0.2 0.1 0.1]. Entiende las opciones de la función huffmandict.

```
A=[1:5];
p=[0.2 0.4 0.2 0.1 0.1];
D=huffmandict(A,p,2,'min');

for i=1:length(A)
    fprintf('Letra Alfabeto %s Código %s\
n',num2str(D{i,1}),num2str(D{i,2}))
end
```

La salida de este código es

```
Letra Alfabeto 1 Código 1  1
Letra Alfabeto 2 Código 0  0
Letra Alfabeto 3 Código 1  0
Letra Alfabeto 4 Código 0  1  1
Letra Alfabeto 5 Código 0  1  0
```

Paso 4

En los ejemplos anteriores hemos supuesto que conocemos las probabilidades de cada símbolo. En condiciones reales estas probabilidades tendrán que ser estimadas/calculadas utilizando un fichero concreto o un conjunto de ficheros. Antes de ver como se estiman/calculan las probabilidades de cada símbolo recordemos una forma de generar símbolos. En el ejemplo siguiente simulamos la generación de 10 símbolos del alfabeto anterior

```
A=[1:5];
p=[0.2 0.4 0.2 0.1 0.1];
rng(0);
stream= randsrc(1,10,[A;p])
```

El resultado de este trozo de código es

```
4     5     1     5     3     1     2     2     5     5
```

Observa que podría no haber aparecido algún símbolo.

Paso 5

Vamos ahora a leer un fichero del que estimaremos la probabilidad de cada letra de un alfabeto. Primero leemos el fichero Don Quijote de la Mancha - Miguel de Cervantes.txt y lo almacenamos en un vector fila de bytes

```
clc; clear all;
fichero= 'Don Quijote de la Mancha - Miguel de Cervantes.txt'
fid=fopen(fichero,'r')
seq=fread(fid,'*uint8');
fclose(fid);
seq=reshape(seq,1,length(seq)); %leidos datos en seq vector fila
fprintf('Tamaño del fichero original en bytes  %d\n',numel(seq))
```

Tamaño del fichero original en bytes 2117266

Paso 6

Calculamos su histograma y lo mostramos

```
letras=[0:255];
histo=histc(seq,letras); %calculamos histograma e indices
bar(letras,histo);
axis('tight');
```

```
xlabel('letras [0:255]');
ylabel('Frecuencias');
title('Histograma');
xlabel('letras [0:255]');
ylabel('Frecuencias');
title('Histograma');
```

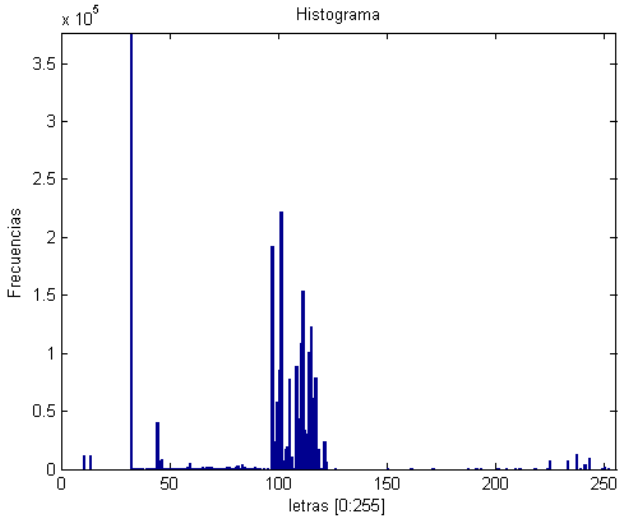

Paso 7

De las 256 letras del alfabeto solo usamos las que aparecen en el fichero 'Don Quijote de la Mancha - Miguel de Cervantes.txt'. Hállalas y calcula sus probabilidades. Puedes utilizar la función find, por ejemplo find(histo>0) que devuelve las posiciones de la matriz histo que almacenan valores mayores que cero. No debes confundir las posiciones de las letras en letras que van de 1 a 256 con los valores de las letras que van de 0 a 255. Escribe el código correspondiente en el paso 7 de Practica02ApellidoNombre.m

Paso 8

A continuación calculamos el diccionario para las letras usadas y sus probabilidades y codificamos la secuencia que teníamos suponiendo que has almacenado en letras_usadas las letras utilizadas (números en [0:255]) y sus probabilidades en prob_letras_usadas.

En el código anterior letras_usadas puede ser elementos en el rango [0:255] o los caracteres correspondientes. Mira la documentación de huffmandict, yo he utilizado números en [0:255]. Finalmente, muestra el número de letras utilizadas y la longitud de la codificación

```
[dict,avglen] = huffmandict(letras_usadas,prob_letras_usadas) ;
seq_codificada = huffmanenco(seq,dict);
fprintf('Número de letras usadas %d\n',numel(letras_usadas))
fprintf('Longitud de la secuencia codificada %d\n',
length(seq_codificada))
```

debe devolver como resultados

Número de letras usadas 111

Longitud de la secuencia codificada 9333683

Paso 9

¿Cómo guardaríamos el fichero codificado?. Podríamos utilizar una cabecera que tuviera las letras usadas (1 byte por letra) y sus probabilidades en formato double (8 bytes por letra) más una letra adicional, por ejemplo, 0 con probabilidad 0 (1 + 8 bytes más) para indicar que ya no tenemos más letras. A continuación guardaríamos la secuencia codificada que necesitaría $\lceil length(seq\_codificadas/8) \rceil$ bytes

En nuestro ejemplo

```
tamagno_comprimido=(length(letras_usadas)+1)*1+ ...
    (length(letras_usadas)+1)*8+ ...
    ceil(length(seq_codificada)/8);
fprintf('Tamaño fichero comprimido en bytes  %d\
n',tamagno_comprimido)
```

que produce

Tamaño fichero comprimido en bytes 1167719

Observa que no hemos discutido cómo terminar la decodificación. El uso de ceil nos dice que podemos tener unos bits al final del fichero codificado que no corresponden a ningún símbolo y que si los decodificamos nos habremos equivocado. Estos problemas los discutiremos al final del guión.

Paso 10

¿Cómo reconstruiríamos el fichero comprimido?. Leeríamos la cabecera y de ella sacaríamos las letras_usadas y prob_letras_usadas, después leeríamos la secuencia codificada que tendríamos que desempaquetar y convertir en una matriz de doubles que sólo contiene 0s y 1s y que llamaríamos seq_codificada, esta seq_codificada va a coincidir con la que obtuvimos en el paso 8. A continuación con letras_usadas y prob_letras_usadas construimos el diccionario que sería el diccionario dict que obtuvimos en el paso 8 y finalmente decodificamos la secuencia usando

```
deco=huffmandeco(seq_codificada,dict);
```

Paso 11

Muy importante, comprobamos que la secuencia original y decodificada son iguales

```
fprintf('¿Coinciden original y comprimido 1(S) 0 (N)?, %d\n',...
    isequal(seq,uint8(deco)))
```

¿Coinciden original y comprimido 1(S) 0 (N)?, 1

Paso 12

Incluye en el paso 12 del fichero Practica02ApellidoNombre.pdf el tamaño del fichero original y el comprimido. Incluye también el factor de compresión.

Tamaño original (en bytes): 2117266
Tamaño comprimido (en bytes): 1167719
Factor de compresión: 1,8132

Escribe tus respuestas aquí.

Paso 13

Crea ahora la siguiente estructura

```
clc; clear all;
N=9;
Fichero=cell(N);
Fichero{1}='constitucion española.txt';
Fichero{2}='Fundacion e Imperio - Isaac Asimov.txt';
Fichero{3}='Cinco semanas en globo - Julio Verne.txt';
Fichero{4}='ptt1.pbm';
Fichero{5}='ptt4.pbm';
Fichero{6}='ptt8.pbm';
Fichero{7}='camera.pgm';
Fichero{8}='bird.pgm';
Fichero{9}='bridge.pgm';
fichero='ptt8.pbm';
```

Paso 14

Para cada uno de los ficheros anteriores: 'constitucion española.txt', 'Fundacion e Imperio - Isaac Asimov.txt', 'Cinco semanas en globo - Julio Verne.txt', ptt1.pbm, ptt4.pbm, ptt8.pbm, camera.pgm, bird.pgm y bridge.pgm escribe en el paso 14 de Practica02ApellidoNombre.m el código Matlab que calcule el tamaño del fichero original, el comprimido usando el código de Huffman y el factor de compresión obtenida en cada uno de los casos. El código Matlab debe comprobar también que los ficheros originales y descomprimidos son iguales.

Completa en el paso 14 de Practica02ApellidoNombre.pdf la tabla siguiente, realiza una comparación crítica de los resultados obtenidos y explica la variación en el factor de compresión.

Escribe tus respuestas aquí

Fichero	Tamaño original	Tamaño Comprimido	FC
constitucion española.txt	112246	64095	1.751244
Fundacion e Imperio - Isaac Asimov.txt	461298	259641	1.776676

Cinco semanas en globo - Julio Verne.txt	487020	275634	1.766908
ptt1.pbm	513249	87435	5.870063
ptt4.pbm	513249	145557	3.526103
ptt8.pbm	513249	115572	4.440946
camera.pgm	65551	59961	1.093227
bird.pgm	65551	57069	1.148627
bridge.pgm	65551	65356	1.002984

Paso 15

Vamos a usar el código de Huffman para comprimir una imagen agrupando de dos en dos sus valores. Lo haremos con una imagen sintética que convertiremos a una secuencia, `seq`

```
clc; close all; clear all;
M=256;
img=uint8(zeros(M));
img(:,129:M)=255;
imshow(img);
img16=uint16(img);
img2=256*img16(:,1:2:size(img,2))+img16(:,2:2:size(img,2));
[U,V]=size(img2);
seq=reshape(img2,1,U*V);
```

Paso 16

Codifica la matriz img, que no agrupa los bytes de dos en dos, usando el código de Huffman, comprueba que coinciden la secuencia original y la decodificación de la comprimida, calcula el espacio que ocupa la imagen comprimida incluida la cabecera y el factor de compresión. Escribe el trozo de código en el paso 16 de Practica02ApellidoNombre.m.

Escribe en el paso 16 de Practica02ApellidoNombre.pdf el factor de compresión calculada.

Escribe tus respuestas aquí

Longitud la secuencia codificada: 65536

Tamaño fichero comprimido en bytes: 8219

Factor de compresión: 7.973719e+00

¿Coinciden original y comprimido 1(S) 0 (N)?, 1

Paso 17

Codifica la matriz img2, que agrupa los bytes de dos en dos, usando el código de Huffman, comprueba que coinciden la secuencia original y la decodificación de la comprimida, calcula el espacio que ocupa la imagen comprimida incluida la cabecera y el factor de compresión. Escribe el trozo de código en el paso 17 de Practica02ApellidoNombre.m.

Escribe en el paso 17 de Practica02ApellidoNombre.pdf el factor de compresión calculada.

Escribe tus respuestas aquí

Longitud la secuencia codificada: 32768

Tamaño fichero comprimido en bytes: 4123

Factor de compresión: 7.947611e+00

¿Coinciden original y comprimido 1(S) 0 (N)?, 1

Nota: El vector de elementos va de 0 a 256*256-1.

Paso 18

¿Cuáles son los factores de compresión para las matrices img2 e img obtenidas en los dos pasos anteriores?. Discute los resultados obtenidos en los dos pasos anteriores en el paso 18 de Practica02ApellidoNombre.pdf.

Escribe tus respuestas aquí

Factor de compresión de img: 7.973719

Factor de compresión de img2: 7.947611

La diferencia entre los factores de compresión de img e img2 indican que se ha alcanzado mejor compresión para la primera imagen. Además, la secuencia original coincide con la decodificada en ambos casos.

Paso 19

Utiliza ahora la imagen goldhill.pgm

```
close all; clear all;
img=imread('goldhill.pgm');
imshow(img);
img16=uint16(img);
img2=256*img16(:,1:2:size(img,2))+img16(:,2:2:size(img,2));
```

Paso 20

Incluye en el paso 20 del fichero Practica02ApellidoNombre.m el código en Matlab que calcula los factores de compresión para estas nuevas matrices img2 e img obtenidas a partir de la imagen goldhill.pgm del paso anterior. Incluye el tamaño de la cabecera. Si no pudieses codificar alguna de las dos matrices explica por qué.

Discute los resultados obtenidos en el paso 20 de Practica02ApellidoNombre.pdf.

Escribe tus respuestas aquí

Resultado para img:

Longitud la secuencia codificada: 490984

Tamaño fichero comprimido en bytes: 63335

Factor de compresión: 1.034752e+00

¿Coinciden original y comprimido 1(S) 0 (N)?, 1

Resultado para img2:

Longitud la secuencia codificada: 414084

Tamaño fichero comprimido en bytes: 136559

Factor de compresión: 2.399549e-01

¿Coinciden original y comprimido 1(S) 0 (N)?, 1

Puesto que el factor de compresión es menor que 1, no está comprimiendo si no expandiendo. Esto se debe a que el tamaño de la cabecera que se envía es demasiado grande.

Nota: Tal y como se realizó en el paso 17, el vector de elementos va de 0 a 256*256-1.

Nota2: El tiempo en calcular los resultados es varias veces mayor que para img.

Paso 21

Lee la secuencia miss_am.yuv, muéstrala y extrae la luminancia de los dos primeros fotogramas

```
clc, close all; clear all;
file_name = 'miss_am.yuv';
file_format = 'QCIF_PAL';
num_of_frames = 30;
[yuv_movie, yuv_array] = readYUV(file_name, num_of_frames, ...
file_format);
```

```
implay(yuv_movie)
fotograma1=yuv_array(:,:,1,1);
fotograma2=yuv_array(:,:,1,2);
figure; imshow(fotograma1);
figure; imshow(fotograma2);
```

Paso 22

Utiliza el código de Huffman para codificar la matriz fotograma2. Escribe en el paso 22 de Practica02ApellidoNombre.m el código en Matlab para calcular el histograma de la imagen original, el tamaño de la matriz comprimida, incluida la cabecera, y su factor de compresión. Comprueba que la matriz original y la decodificación de la comprimida coinciden.

Incluye el histograma, el tamaño de la matriz original y el de la comprimida (con cabecera) en el paso 22 de Practica02ApellidoNombre.pdf. Escribe también el factor de compresión

Escribe tus respuestas aquí

Tamaño del fichero original en bytes 25344

Longitud la secuencia codificada: 142360

Tamaño fichero comprimido en bytes: 19262

Factor de compresión: 1.315751e+00

¿Coinciden original y comprimido 1(S) 0 (N)?, 1

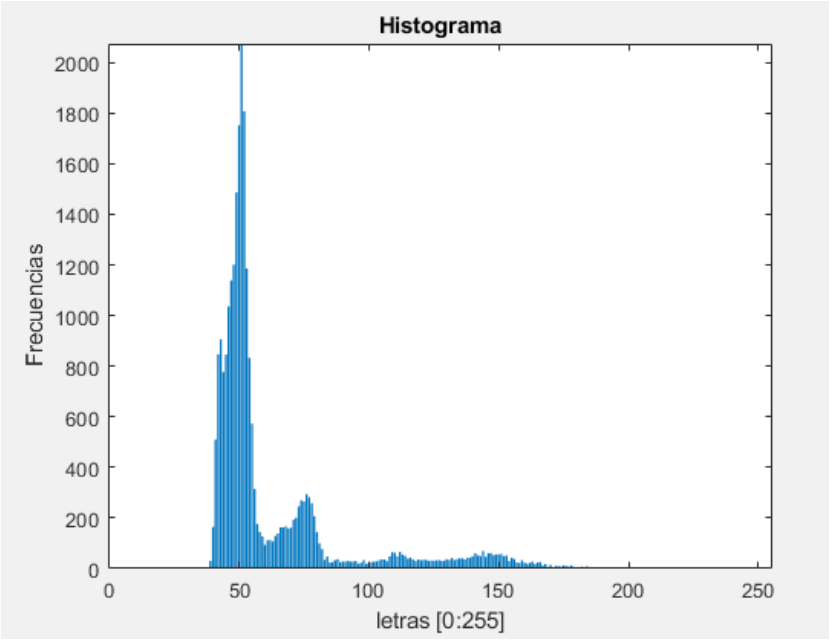

Paso 23

Como puedes comprobar la nueva representación de la imagen ocupa menos espacio que la imagen original pero la reducción del tamaño no es grande. Escribe código en Matlab que dibuje el histograma de fotograma2-fotograma1, codifique la matriz diferencia usando Huffman, compruebe que fotograma2 coincide con su reconstrucción y calcule el tamaño de fotograma2-fotograma1 comprimido, incluida su cabecera. Incluye el código en el paso 23 de Practica02ApellidoNombre.m. Este ejercicio puedes hacerlo de dos formas según codifiques las diferencias. Realízalo como consideres más apropiado.

Incluye el histograma de fotograma2-fotograma1, y el tamaño de la matriz comprimida (con cabecera) en el paso 23 de Practica02ApellidoNombre.pdf. Escribe también el factor de compresión.

Escribe tus respuestas aquí

Longitud la secuencia codificada: 39937

Tamaño fichero comprimido en bytes: 5191

Factor de compresión: 4.882296e+00

¿Coinciden original y comprimido 1(S) 0 (N)?, 1

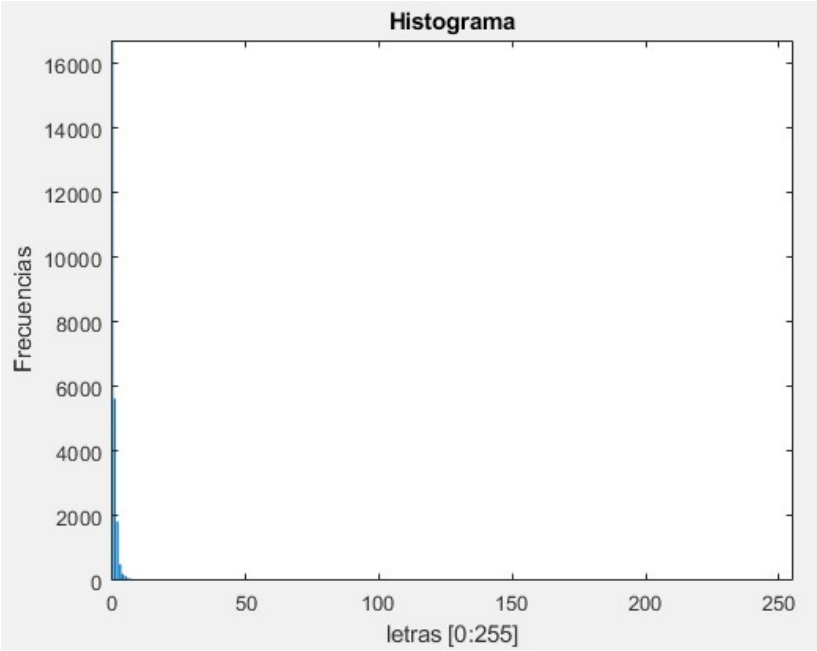

Paso 24

Compara en el paso 24 del fichero Practica02ApellidoNombre.pdf los tamaños de las matrices fotograma2 y fotograma2-fotograma1 comprimidos obtenidos en los pasos 22 y 23. ¿A qué se debe la mejora?

Escribe tus respuestas aquí

Tamaño de fotograma2 comprimida: 19262

Tamaño de fotograma2-fotograma1 comprimida: 5191

La mejora se debe a que en la matriz de diferencias solo deben codificarse unos pocos valores, ya que fotograma1 y fotograma2 son prácticamente iguales.

Paso 25

En el paso 9 nos dejamos pendiente detectar que habíamos decodificado toda la secuencia de 0s y 1s. Discute en el paso 25 de Practica02ApellidoNombre.pdf posibles soluciones a este problema.

Escribe tu respuesta aquí

Solución: Indicar el número de bits que tiene que decodificar para que se detenga el proceso en caso de alcanzar dicha cantidad.

Paso 26

En el paso 9 definimos una cabecera. Se te ocurre alguna(s) mejora(s) que ahorre(n) espacio?. Incluye tu respuesta en el paso 26 de Practica02ApellidoNombre.pdf.

Escribe tu respuesta aquí

Utilizando códigos de Huffman canónicos podríamos enviar únicamente las longitudes de las palabras, reduciendo así el tamaño de la cabecera.

Podría realizarse una codificación, empleando algún método de codificación diferente, la propia cabecera para que sea menor que la actual.